AlphaDetect

基于神经符号自动推理的 可解释 MIMO 检测算法发现

研究提案

2026 年 4 月

摘　要

本文提出 **AlphaDetect**，一个用于自动发现可解释 MIMO 检测算法的统一框架。AlphaDetect 将算法发现建立在形式化推理基础之上，通过四个紧密集成的组件实现：(i) 带类型的领域特定语言（Typed DSL），以精确的数学类型和算法组合子编码信号处理与概率推断原语；(ii) 问题变换库（Problem Transformation Library），将中间概念的发明重新定义为类型化变换的见证生成；(iii) 计算机代数系统（CAS），逐步执行算法更新方程的符号推导；(iv) LLM 增强的结构映射引擎（SME），利用 LLM 生成的谓词表示实现跨领域的概念迁移。这些组件协同解决算法发现的核心挑战——发明新的中间概念（如将 MIMO 模型识别为因子图，或引入腔分布），这一过程无法归结为在固定概念空间上的搜索。本文详细描述了完整的系统架构、每个组件及其实现方式，并通过案例研究（EP-MIMO、GTA、BP 引导的球形译码）展示已知算法如何在该框架内被重新推导。

本文档详细描述 AlphaDetect 研究项目。

目 录

1 引言与动机 **3**
1.1 MIMO 检测问题 . . . 3
1.2 算法发现的鸿沟 . . . 3
1.3 为何标准方法不足 . . . 3
1.4 研究愿景 . . . 3

2 概念创新问题 **3**
2.1 算法发现中的“概念”是什么？ . . . 3
2.2 算法组合作为特例 . . . 4

3 系统架构 **4**

4 带类型的领域特定语言 **5**
4.1 设计理念 . . . 5
4.2 类型层次 . . . 5
4.3 原语操作 . . . 6
4.4 算法组合子 . . . 6
4.5 类型适配器库 . . . 7

5 问题变换库 **7**
5.1 变换作为概念生成器 . . . 7
5.2 变换空间的可搜索性 . . . 7

6 CAS 驱动的推导引擎 **8**
6.1 CAS 的角色 . . . 8
6.2 CAS 实现细节 . . . 8

7 LLM 增强的结构映射引擎 **8**
7.1 结构映射理论 . . . 8
7.2 表示瓶颈与 LLM 的解决方案 . . . 9
7.3 SME 匹配与候选推断 . . . 9
7.4 LLM 增强的语义匹配 . . . 9
7.5 LLM 作为源域推荐器 . . . 10

8 搜索引擎与评估 **10**
8.1 搜索策略 . . . 10
8.2 复杂度评估器 . . . 10
8.3 性能预言机 . . . 10
8.4 概念空间自扩展 . . . 10

9 案例研究 **10**
9.1 案例 1：EP-MIMO 的自动推导 . . . 10
9.2 案例 2：高斯树近似（GTA） . . . 12
9.3 案例 3：BP 引导的球形译码 . . . 12
9.4 可发现性比较 . . . 13

10 讨论：范围与局限 **13**
10.1 DSL 粒度权衡 13
10.2 结构直觉的不可约角色 13
10.3 公理探测作为语义后备 13

11 相关工作 **14**

12 总结与贡献 **14**

1. 引言与动机

1.1. MIMO 检测问题. 大规模 MIMO 系统是 5G 及未来通信系统的核心。给定接收信号模型

$$\mathbf{y} = \mathbf{H}\mathbf{x} + \mathbf{n}, \qquad \mathbf{n} \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I}), \tag{1}$$

其中 $\mathbf{H} \in \mathbb{C}^{N_r \times N_t}$ 为信道矩阵，$\mathbf{x}$ 为从有限星座集 $\mathcal{S}$ 中取值的发送符号向量，$\mathbf{y}$ 为接收向量，目标是在多项式计算复杂度下以最小误比特率（BER）估计 $\mathbf{x}$。对一般星座集而言，最优最大似然检测是 NP 难的，这促使研究者提出了大量近似算法。

1.2. 算法发现的鸿沟. 当前最先进的 MIMO 检测器——ZF、MMSE、V-BLAST、球形译码、KBEST、因子图上的 BP、高斯树近似（GTA）、期望传播（EP）、AMP 及其众多混合算法——是人类研究者经过数十年的工作而发现的。每一次突破不仅需要数学推导，更需要*发明新的概念*：将检测问题表示为图上的概率推断、将搜索空间建模为树结构、用 Chow-Liu 最大生成树近似环状因子图、或引入腔分布的概念。

核心挑战

机器能否系统性地发现这样的*概念创新*，而不仅仅是在固定的算法空间内优化？

1.3. 为何标准方法不足.

神经架构搜索（NAS）与深度展开。 这类方法学习固定计算图的参数，无法发现新的算法结构。

基于 LLM 的算法进化。 如 FunSearch 或 AlphaCode 等方法通过从 LLM 中采样来进化程序。我们明确排除这类方法：发现的程序不透明，无法进行形式化验证。

经典神经符号 AI。 现有系统擅长处理规则已知且解空间固定的问题（如数独、从公理出发的定理证明）。算法发现本质不同：不存在规范目标，且解空间——即有用算法的集合——本身是未知的。

1.4. 研究愿景. AlphaDetect 以**可解释性**为目标进行算法发现。发现的算法中的每一步都必须可溯源到形式化推导、类型正确的原语组合或经过验证的代数操作。系统围绕四个紧密集成的组件构建，共同覆盖算法创新的全部范围：

1. **带类型的 DSL**：以精确的数学类型、复杂度标注和高阶组合子编码算法原语。
2. **问题变换库**：将 “中间变量的发明” 形式化为对子问题施加类型化变换。
3. **CAS 驱动的推导引擎**：在高层算法结构确定后，以符号方式推导算法的更新方程。
4. **LLM 增强的结构映射引擎**：发现跨领域的类比并提出新的概念假设。

2. 概念创新问题

2.1. 算法发现中的 “概念” 是什么？. 当研究者提出将 MIMO 检测建模为因子图上的推断时，她并非在应用已知规则——而是在 *扩展概念空间本身*。我们将 MIMO 算法发

现中遇到的概念创新归纳为三种主要形式。

创新类型	示例	难度
结构类比	MIMO 后验 $\leftrightarrow$ 因子图推断	高（跨领域）
优化变换	KL 最小化 $\rightarrow$ 通过坐标下降得到 EP	中（CAS 可推导）
算法组合	BP 置信度引导球形译码搜索顺序	低–中（类型搜索）

观察 2.1. 中间变量的发明几乎从不是自由的创造性行为，而是施加问题变换所产生的见证（*witness*）。$\mathbf{H}$ 的 QR 分解产生 $\mathbf{Q}$ 和 $\mathbf{R}$ 作为见证；拉格朗日松弛产生对偶变量作为见证；近似分布假设产生站点近似作为见证。

这一观察对 AlphaDetect 至关重要：系统不发明变量，而是搜索变换空间，见证作为副产品自然出现。

2.2. 算法组合作为特例. 一大类具有实际重要性的创新并非新概念，而是现有算法的新颖组合。例如 BP 引导的球形译码、OSIC（带 MMSE 排序的有序 SIC）、迭代 MMSE–BP 以及搜索树上的消息传递检测器。这些可以通过在 DSL 的类型化组合子（第4节）下搜索已知算法模块的组合空间来发现。

3. 系统架构

AlphaDetect 由四个核心模块组成——带类型的 DSL、问题变换库、CAS 推导引擎和 LLM 增强的结构映射引擎——由搜索引擎协调，并通过复杂度评估器与性能预言机进行评价。图1展示了整体信息流。

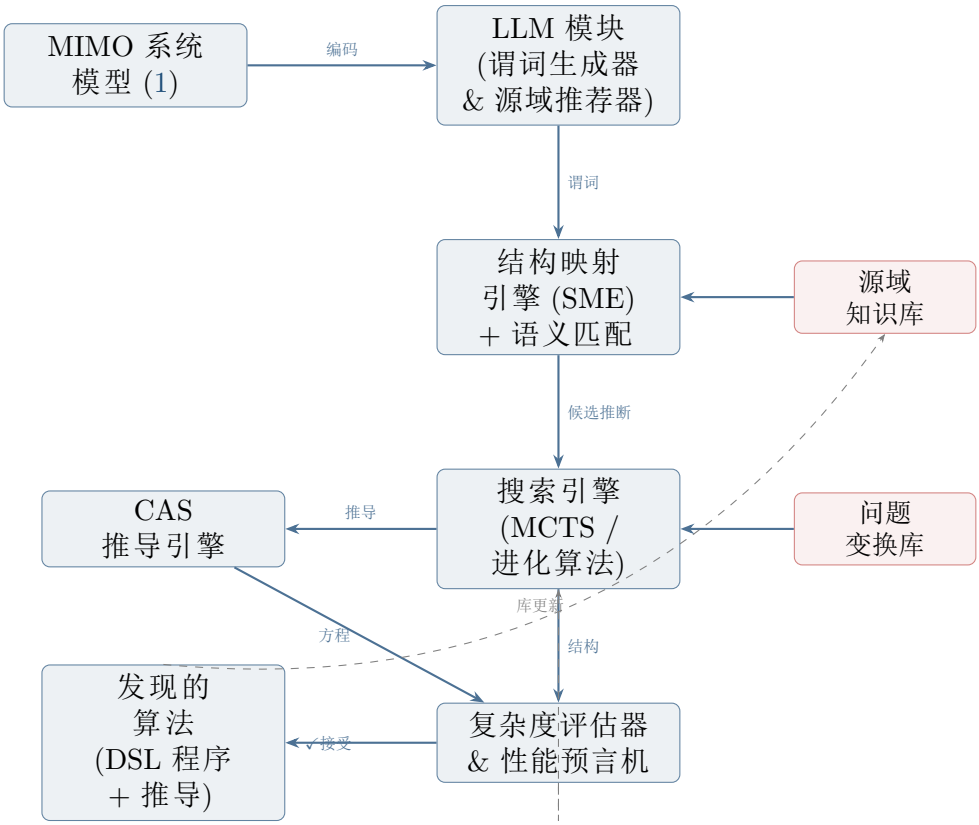

图 1: AlphaDetect 系统架构。实线箭头表示主要数据流；虚线箭头表示反馈（搜索剪枝与库扩充）。

系统运行方式如下。给定一个 MIMO 系统模型，LLM 模块将其编码为谓词结构并推荐候选源域。SME 在目标域和源域之间进行结构对齐，产生候选推断，假设新的概念结构（如 “MIMO 系统可以表示为因子图”）。然后搜索引擎在 DSL 组合和问题变换的空间中导航，以候选推断、类型兼容性和复杂度约束为引导。当选定一个高层算法结构后，CAS 推导精确的更新方程。最终的算法通过复杂度和性能评估后，被反馈以丰富源域库和 DSL 原语集，从而实现自扩展的概念空间。

4. 带类型的领域特定语言

4.1. 设计理念. DSL 是 AlphaDetect 的语义基底。DSL 中的每一个表达式都携带精确的类型；每一个原语都附有复杂度标注；每一个组合子都有类型签名，因此类型系统自动约束哪些组合是合法的，无需对涉及的概念进行语义理解。

核心洞见

已发现中间对象的类型签名替代了人类的语义理解。如果系统构造了一个类型为 `FactorGraph[Variable, Factor]` 的对象，所有接受 `FactorGraph` 作为输入的算法立即可用——无论系统是否 “理解” 因子图的含义。

4.2. 类型层次. DSL 将类型组织为四个层次。

第 0 层——数学基础。 标量、张量、具有结构子类型的矩阵（Hermitian、PositiveDefinite、UpperTriangular、Unitary 等）。

第 1 层——信号处理对象。 `MIMOSystem`、`Constellation`、`SoftEstimate`、`HardEstimate`、`LLR`、`Subspace`。

第 2 层——概率/图模型对象。

- `Distribution[X]` ⊃ `Gaussian[X]`、`DiscreteDistribution[X]`、`MixtureDist[X]`
- `Belief` ⊃ `GaussianBelief`、`DiscreteBelief`
- `BeliefSet[n]` ⊃ `GaussianBeliefSet[n]`、`DiscreteBeliefSet[n]`
- `Graph[Node,Edge]` ⊃ `Tree`、`BipartiteGraph` ⊃ `FactorGraph`、`WeightedGraph`
- `SearchTree[State]`、`CandidateList[T,Score]`

第 3 层——算法控制对象。 `Ordering`、`Heuristic`、`Criterion`、`Complexity`。

4.3. 原语操作. 表1列出了部分代表性原语，展示 DSL 的表达范围。

表 1: 代表性 DSL 原语及其类型签名与复杂度。

原语	类型签名	复杂度
qr	Matrix$[m,n]$ → (Unitary$[m]$ × UpperTriangular)	$O(mn^2)$
mmse_equalize	MIMOSystem → (SoftEstimate, ErrorCov)	$O(N_t^3)$
system_to_factor_graph	MIMOSystem → FactorGraph	$O(N_rN_t)$
find_spanning_tree	WeightedGraph → Tree	$O(E\log V)$
gaussian_bp_message	(Factor, GaussianMessages) → GaussianMessage	$O(N_t)$
bp_message_factor_to_var	(Factor, Messages) → Message	$O(M^d)$
sic_detect_one	(MIMOSystem, Int, Partial) → (Symbol, MIMOSystem)	$O(N_rN_t)$
expand_node	(SearchTree, State) → List[State, Cost]	$O(M)$
select_top_k	(CandidateList, k) → CandidateList	$O(n\log k)$
mutual_info_weights	(GaussianBeliefSet, MIMOSystem) → WeightedGraph	$O(N_t^2)$

4.4. 算法组合子. 组合子是高阶类型化算子，在不违反类型安全的前提下组合原语。

```
sequence   : (Op[A->B], Op[B->C]) -> Op[A->C]
guide      : (Op[A x Heuristic -> B], Op[A -> Heuristic]) -> Op[A->B]
nest       : (IterOp[A->B], Op[SubProblem->SubResult]) -> Op[A->B]
iterate    : (Op[S->S], init:S, convergence:S*S->Bool) -> S
fold_layers : (LayerOp, Ordering[Nt], MIMOSystem) -> HardEstimate
refine     : (Op[A->B], Op[B*A->B], n_steps:Int) -> Op[A->B]
parallel_merge : (Op[A->B1], Op[A->B2], Op[(B1,B2)->C]) -> Op[A->C]
```

代码 1: 核心组合子签名

4.5. 类型适配器库. 适配器桥接不兼容的类型，是发现跨范式组合的主要机制。

```
beliefs_to_ordering     : BeliefSet[n] -> Ordering[n]
beliefs_to_heuristic    : BeliefSet[n] -> Heuristic[PartialSymbolVec ->
    Score]
beliefs_to_candidates   : DiscreteBeliefSet[n] -> CandidateList[SymbolVec,
     Prob]
estimate_to_beliefs     : (SoftEstimate[n], ErrorCov) -> GaussianBeliefSet
    [n]
covariance_to_graph     : PositiveDefinite[n] -> WeightedGraph[n, Real]
partial_to_reduced_sys : (MIMOSystem, PartialDecision[k]) -> MIMOSystem[
    Nt-k, Nr]
```

代码 2: 桥接概率置信度与搜索控制的关键适配器

发现一个新的跨范式算法，归结为在原语、组合子和适配器中寻找一条类型正确的路径。搜索引擎枚举候选路径；复杂度评估器剪除不可行的路径；在基准信道模型上的性能从幸存者中进行选择。

5. 问题变换库

5.1. 变换作为概念生成器. 中间概念的发明归结为施加问题变换，其输出（“见证”）成为新的对象。变换库按类别编目已知模式。

表 2: 按类别组织的问题变换及其类型签名与见证对象。

类别	变换	见证
代数	qr: $\mathbf{H} \to \mathbf{QR}$	$\mathbf{Q}, \mathbf{R}$
	woodbury: $(A + UCV)^{-1} \to$ 小规模求逆	中间矩阵
	complete_square: $f(x) \to g(x-h)^2 + k$	h, k
概率	introduce_latent: $p(\mathbf{x}) \to \int p(\mathbf{x}, \mathbf{z})\, d\mathbf{z}$	$\mathbf{z}$
	factorize_joint: $p(\mathbf{x}_{1:n}) \to \prod p(x_i \mid pa_i)$	图、CPDs
	exponential_family: $p \to \exp(\theta^\top T(x) - A(\theta))$	θ、T
优化	lagrangian_relax: $\min f$ s.t. $g \le 0 \to \min_x \max_\lambda \mathcal{L}$	λ
	coordinate_descent: $\min_{x,y} f \to$ 交替最小化	子目标
	surrogate_objective: $f \to \tilde{f} \ge f$	替代目标、界
结构	to_factor_graph: 系统 $\to$ FactorGraph	因子节点
	tree_approximate: Graph $\to$ Tree	树、近似误差

5.2. 变换空间的可搜索性. 对当前问题施加变换 T 产生一个见证和一个变换后的子问题。子问题与已知的可解模式（在 DSL 类型系统内）进行匹配。两个信号表明一个有用的变换：

- 变换后的问题具有更低的复杂度类；或

- 变换后的问题类型匹配某个已知高效算法的输入。

搜索引擎使用复杂度引导的启发式在变换空间中导航：优先选择降低复杂度类或增加结构约束的变换。

6. CAS 驱动的推导引擎

6.1. CAS 的角色. 当搜索引擎选定了高层算法结构（哪些原语、哪些组合子、什么变换序列）后，CAS 接管以推导精确的更新方程。CAS 不发明概念，而是执行以下操作：

1. 目标函数的符号展开（KL 散度、MSE 等）
2. 泛函微分与驻点条件
3. 高斯封闭：边缘化、条件化、矩计算
4. 通过符号渐近分析确定复杂度类

6.2. CAS 实现细节. CAS 操作符合 DSL 类型系统的符号表达式。关键能力包括：

- **高斯代数**：给定联合高斯 $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，以封闭形式计算边缘分布、条件分布和 Schur 补。
- **指数族微积分**：给定指数族形式的分布 $\exp(\theta^\top T(x) - A(\theta))$，计算自然梯度、充分统计量和矩参数。
- **KL 散度展开**：对参数族符号展开 $\mathrm{KL}(q\|p)$ 或 $\mathrm{KL}(p\|q)$，并推导关于变分参数的驻点条件。
- **精度域算术**：以精度（信息）形式维护置信度，通过减法而非矩阵求逆实现高效的腔计算。
- **渐近复杂度分析**：给定符号表达式，确定关于 N_t、N_r 和 M 的渐近复杂度类。

7. LLM 增强的结构映射引擎

7.1. 结构映射理论. Gentner 的结构映射理论（SMT）[1] 提出，类比不是表面相似性而是 结构对齐：源域和目标域的关系结构之间的双射映射。三个指导原则是：

1. **结构一致性**：映射是一对一的。
2. **系统性原则**：高阶关系结构（关系之间的关系）优先于孤立的属性匹配。
3. **候选推断**：存在于源域但在目标域中没有对应的谓词被预测为可能在目标域中成立——这是知识迁移的机制。

结构映射引擎（SME）[2] 在计算上实现了 SMT，产生按结构评估分数排名的全局映射（gmaps）。

7.2. 表示瓶颈与 LLM 的解决方案. SME 需要以手工构建的谓词结构来描述域。Chalmers 等人 [5] 批评了这一点：创造性工作可能在于表示设计本身而非 SME。AlphaDetect 通过使用 LLM 作为自动化谓词生成器来解决这一问题。

经过微调（或少样本提示）的 LLM 将数学概念编码为符合 DSL 本体的谓词结构：

```
;; Target domain: MIMO posterior inference
(coupled-variables x1 ... xNt H)
(intractable exact-marginal posterior)
(goal marginal-inference posterior x_i)
(additive-noise observation sigma-squared)
(constraint discrete-valued x constellation)
(complexity-target polynomial)
```

代码 3: LLM 生成的 MIMO 后验推断问题的谓词编码

```
;; Source domain: Factor-graph probabilistic inference
(coupled-variables v1 ... vN factor-graph)
(factorized-distribution p factors)
(graph-structure factor-graph variables factors)
(message-passing bp factor-graph)
(tractable message-passing tree)
(intractable exact-message-passing general-graph)
(tree-decomposition general-graph tree)
(optimality Chow-Liu KL-optimal-tree-approximation)
```

代码 4: LLM 生成的因子图推断的谓词编码（源域）

7.3. SME 匹配与候选推断. 对上述两组谓词运行 SME 产生以下全局映射：

源域（因子图推断）	目标域（MIMO 检测）
`coupled-variables vi (factor-graph)`	`coupled-variables xi (H)`
`intractable exact-message-passing`	`intractable exact-marginal`
`goal marginal-inference`	`goal marginal-inference`

候选推断（存在于源域但目标域中缺失的谓词）：

1. `(graph-structure ??? variables factors)` ⇒ *MIMO 系统可以表示为因子图。*
2. `(message-passing bp ??? → marginals)` ⇒ *BP 可以应用于 MIMO 因子图。*
3. `(tree-decomposition ??? tree)` ⇒ *用生成树近似 MIMO 因子图。*

这三个推断依次对应了人类研究者发现 GTA 的概念步骤。

7.4. LLM 增强的语义匹配. 标准 SME 需要相同的谓词名（函子）才能产生匹配。我们用 LLM 嵌入的余弦相似度替代之：

$$m(\pi_s, \pi_t) = \frac{\mathbf{e}_s^\top \mathbf{e}_t}{\|\mathbf{e}_s\|\|\mathbf{e}_t\|}, \qquad \mathbf{e} = \text{LLM_embed}(\text{functor} \oplus \text{args description}) \tag{2}$$

这使 SME 能够跨词汇表（如 `propagate` ↔ `transmit`）和跨不同研究社区编码的域发现类比。

7.5. LLM 作为源域推荐器. 给定目标谓词集，LLM 通过按估计的结构相似度对数学/工程领域排序来推荐候选源域。对于 MIMO 检测，典型推荐包括：统计物理（Ising 推断）、LDPC 译码、马尔可夫随机场标注、格约化和凸优化。然后由 LLM 将每个推荐域编码为谓词，SME 计算形式化的全局映射分数。

8. 搜索引擎与评估

8.1. 搜索策略. 搜索引擎在 DSL 组合、问题变换和 SME 建议的概念假设的联合空间中导航，采用两种互补策略：

- **MCTS（蒙特卡洛树搜索）：**搜索树中的每个节点表示一个部分算法（到目前为止应用的 DSL 操作和变换序列）。扩展添加一个新的原语、组合子或变换。通过在小规模 MIMO 实例上的轻量模拟进行回滚估计性能。UCB1 准则平衡探索与利用。
- **进化搜索：**候选 DSL 程序的种群通过变异（替换一个原语）、交叉（两个程序之间交换子表达式）和选择（保留性能复杂度比最优的程序）进行进化。

8.2. 复杂度评估器. 每个候选算法都附有由 CAS 推导的符号复杂度表达式。评估器通过拒绝复杂度超出用户指定预算（如实时检测的 $O(N_t^3)$）的候选来把控搜索。

8.3. 性能预言机. 通过复杂度门控的候选算法在基准测试套件上评估，该套件包括：

- 瑞利 i.i.d. 信道（$N_t = N_r = 16, 32, 64$）
- 相关信道（指数相关模型）
- 病态信道（条件数 > 100）
- 多种星座（QPSK、16-QAM、64-QAM）

性能以目标 SNR 值下的 BER 衡量。在任何场景中相对最佳已知基线实现 BER 改进的算法将被标记供人工审查。

8.4. 概念空间自扩展. 系统的一个关键设计特征是自扩展概念空间：

1. 成功的算法组合被添加到源域库（SME）和作为新原语（DSL），通过库学习（Library Learning）[3] 实现。
2. 丰富后的库使得更高阶的概念迁移成为可能，而这在初始原语集下是不可能的。

这镜像了 DreamCoder 的唤醒–抽象–梦境循环，应用于算法发现而非程序综合。

9. 案例研究

下面通过三个详细的案例研究展示已知的 MIMO 检测算法如何在 AlphaDetect 框架内被重新推导。每个案例追踪从问题规范到最终算法的完整路径，展示系统的哪些组件在每一步被调用。

9.1. 案例 1：EP-MIMO 的自动推导. 用于 MIMO 检测的期望传播（EP）[6] 是一种其核心创新——腔分布、倾斜分布和矩匹配——通常被呈现为创造性洞见的算法。我们展示所有这些 “概念” 在给定适当搜索决策后作为 CAS 推导引擎的代数副产品出现。

设定。 贝叶斯后验为

$$p(\mathbf{x}|\mathbf{y}) \propto \underbrace{\mathcal{N}(\mathbf{y}; \mathbf{H}\mathbf{x}, \sigma^2\mathbf{I})}_{f_0(\mathbf{x})} \cdot \prod_{i=1}^{N_t} \underbrace{p(x_i)}_{f_i(x_i)}. \tag{3}$$

精确边缘化复杂度为 $O(M^{N_t})$，被复杂度评估器标记为不可行。

搜索决策 1——在高斯族中近似。 搜索引擎选择 `approximate_in_family`(p, `Gaussian`, $\mathrm{KL}_{\mathrm{reverse}}$)，产生见证 $q(\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$。

搜索决策 2——匹配因式分解。 搜索引擎施加 `match_factorization`，产生 $q(\mathbf{x}) \propto f_0(\mathbf{x}) \cdot \prod_i \tilde{q}_i(x_i)$，其中站点近似 $\tilde{q}_i = \mathcal{N}(\mu_i, \sigma_i^2)$ 作为见证。

搜索决策 3——坐标下降。 搜索引擎选择对 $\tilde{q}_i$ 进行 `coordinate_descent`。然后 CAS 推导在所有其他因子固定时 $\tilde{q}_i$ 的最优更新：

$$\underbrace{q_{-i}(\mathbf{x}) \triangleq \frac{q(\mathbf{x})}{\tilde{q}_i(x_i)}}_{\text{腔分布（CAS 见证）}} = \mathcal{N}(\boldsymbol{\mu}_{-i}, \boldsymbol{\Sigma}_{-i}) \tag{4}$$

$$\underbrace{\hat{p}_i(x_i) \propto f_i(x_i) \cdot q_{-i}^{\mathrm{marg}}(x_i)}_{\text{倾斜分布（CAS 见证）}} = \sum_{s \in \mathcal{S}} w_s\, \delta(x_i - s), \quad w_s \propto \mathcal{N}(s; \mu_{-i}, \sigma_{-i}^2) \tag{5}$$

$$\tilde{q}_i^{\mathrm{new}}: \quad \mathbb{E}_{\hat{p}_i}[x_i],\ \mathrm{Var}_{\hat{p}_i}[x_i] \quad \leftarrow \quad O(M)\text{计算} \tag{6}$$

腔参数通过精度域减法获得（CAS 步骤）：

$$\sigma_{-i}^{-2} = \sigma_{q,i}^{-2} - \sigma_{\tilde{q}_i}^{-2}, \qquad \mu_{-i}\sigma_{-i}^{-2} = \mu_{q,i}\sigma_{q,i}^{-2} - \mu_{\tilde{q}_i}\sigma_{\tilde{q}_i}^{-2}. \tag{7}$$

核心洞见

从 CAS 的角度看，腔分布和倾斜分布仅仅是为简化表达式而引入的中间代数量。人类研究者赋予它们名称和直觉；CAS 什么都不需要。

复杂度验证。 完整的 EP 迭代复杂度为 $O(N_{\mathrm{iter}} \cdot N_t \cdot (N_t^2 + M))$，为多项式——被评估器接受。

多路径探索。 不同的搜索决策产生不同的算法：

KL 方向	因式分解	族	算法
$\mathrm{KL}(q\|p)$	匹配先验	高斯	**EP-MIMO**
$\mathrm{KL}(q\|p)$	平均场	指数族	变分贝叶斯
$\mathrm{KL}(p\|q)$	匹配先验	高斯	α-散度近似
–	–	高斯 + Laplace	Laplace-EP

EP-MIMO 的 DSL 表示。

$$\begin{aligned}&\texttt{sites}_0 = \texttt{init_gaussian_sites}(N_t)\\&\hat{\mathbf{x}} = \texttt{iterate}\Big(\texttt{ep_update_step}(sys, \texttt{sites}),\ \texttt{sites}_0,\ \text{convergence}\Big)\end{aligned}$$

其中 `ep_update_step` 内部调用 CAS 推导的腔计算、倾斜分布构造和矩匹配。

9.2. 案例 2：高斯树近似（GTA）. GTA[7] 例证了一种结构创新：关键洞见是用最优生成树近似全连接的 MIMO 因子图。此案例展示 SME 模块如何驱动 CAS 本身无法推导的结构概念的发现。

SME 驱动的假设生成。 给定 MIMO 后验推断问题作为目标域，LLM 推荐因子图推断作为候选源域。SME 对齐产生候选推断："MIMO 系统可以表示为因子图，因子图可以用生成树近似。"

DSL 程序。 搜索引擎在 SME 候选推断的引导下构造：

$$\begin{aligned}&\texttt{beliefs}_0 = \texttt{estimate_to_beliefs}(\texttt{mmse_equalize}(sys))\\&\texttt{weights} = \texttt{mutual_info_weights}(\texttt{beliefs}_0,\ sys)\\&\texttt{tree} = \texttt{find_spanning_tree}(\texttt{weights},\ objective = \max)\\&\hat{\mathbf{x}} = \texttt{iterate}(\texttt{gaussian_bp_on_tree}(\texttt{tree}),\ \texttt{beliefs}_0,\ \text{convergence})\end{aligned}$$

CAS 的角色。 CAS 在树结构上推导高斯 BP 消息方程。其角色是次要的：一旦给定树结构就求解消息传递更新方程。

关键发现瓶颈。 Chow-Liu 权重函数（变量对之间的互信息）是一个无法仅从目标函数推导的关键选择。它需要 (a) SME 从信息论迁移 Chow-Liu 最优性结果，或 (b) 搜索引擎在基准上评估多个候选权重函数。

9.3. 案例 3：BP 引导的球形译码. BP 引导的球形译码例证了算法组合：两种现有范式（置信传播和树搜索）通过类型适配器组合以产生更优的混合算法。

DSL 程序。

$$\begin{aligned}&\texttt{beliefs} = \texttt{iterate}(\texttt{gaussian_bp_message},\ \texttt{fg},\ 5\text{步})\\&\texttt{ordering} = \texttt{beliefs_to_ordering}(\texttt{beliefs})\\&\hat{\mathbf{x}} = \texttt{best_first_search}(\texttt{tree}(sys, \texttt{ordering}),\ \texttt{beliefs_to_heuristic}(\texttt{beliefs}),\ K)\end{aligned}$$

发现机制。 搜索引擎通过枚举类型正确的路径找到此组合：`gaussian_bp_message` 产生 `GaussianBeliefSet`；适配器 `beliefs_to_ordering` 将其转换为树搜索所需的 `Ordering`；适配器 `beliefs_to_heuristic` 将其转换为用于剪枝的 `Heuristic`。无需结构类比或 CAS 推导——纯类型引导的组合即可。

OSIC 的 DSL 表示。 作为另一个组合示例，带 MMSE 排序的 BLAST（OSIC）为：

$$\hat{\mathbf{x}} = \texttt{fold_layers}\Big(\texttt{sic_detect_one},\ \texttt{beliefs_to_ordering}(\texttt{estimate_to_beliefs}(\cdot)),\ \mathit{sys}\Big)$$

表 3: 三个案例研究的自动化可发现性比较。

方面	EP-MIMO	GTA	BP 引导的 SD
创新类型	优化	结构	组合
主要组件	CAS	SME + 搜索	DSL 类型搜索
关键概念跳跃	CAS 可推导	树近似（结构）	类型适配器
CAS 角色	核心	次要	无
SME 角色	无	核心	无
难度	中	中–高	低–中
瓶颈	KL 方向 + 因式分解	Chow-Liu 权重函数	无显著瓶颈

9.4. 可发现性比较. **核心发现。**EP 在 CAS 下更易推导，因为其核心创新来自优化分解——一个纯代数过程——而 GTA 的树近似是一个需要跨领域类比推理的结构选择。BP 引导的球形译码最容易发现，只需类型引导的组合。

10. 讨论：范围与局限

10.1. DSL 粒度权衡. AlphaDetect 中最关键的设计选择是 DSL 的粒度：

- **过粗**（仅矩阵运算）：GTA 和 EP 无法推导，因为因子图类型不存在。
- **过细**（树近似作为原语）：发现被平凡引导；系统已知答案。
- **目标粒度**：包含解的各个组件（因子图类型、生成树算法、消息传递步骤、矩计算），但不包含预组装的组合。“Chow-Liu 的权重函数” 是被发现的，而非给定的。

10.2. 结构直觉的不可约角色. GTA 分析揭示了一个根本性的不对称：*基于优化的创新*（EP、EM、ADMM）一旦目标和因式分解被选定即可由 CAS 推导，而*基于结构的创新*（树近似、MIMO 的格表示）需要跨域的类比推理。没有任何形式化机制能完全自动化结构直觉；SME 提供了一个系统性的——但不完美的——替代。

10.3. 公理探测作为语义后备. 当一个发现的中间对象在 DSL 中没有类型时（例如因其来自神经网络组件），*公理探测*提供语义后备：

- 测试对象是否满足图公理（邻接、无环）⇒ 赋予 `Tree` 类型。
- 测试度量公理（非负性、对称性、三角不等式）⇒ `Metric` 类型。
- 测试高斯矩条件 ⇒ `GaussianDistribution` 类型。

一旦赋型，该对象即可参与类型化的 DSL 组合。

11. 相关工作

Gentner (1983) [1] 结构映射理论：类比作为关系结构对齐。AlphaDetect 跨域迁移机制的基础。

Falkenhainer, Forbus & Gentner (1989) [2] 结构映射引擎：SMT 的算法实现。AlphaDetect 以 LLM 语义匹配扩展 SME。

Ellis 等 (2021) [3] DreamCoder：通过抽象共享程序片段进行库学习。AlphaDetect 采用唤醒–抽象–梦境循环实现概念自扩展机制。

Chalmers, French & Hofstadter (1992) [5] 对 AI 方法论中类比表示瓶颈的批评。直接促使了我们基于 LLM 的谓词生成。

Minka (2001) [6] 期望传播用于近似贝叶斯推断。案例 1 中被重新推导的算法。

Turney (2008) [4] 潜在关系映射引擎：不需要手工编码 LISP 输入的 SME，使用向量空间表示。与我们的 LLM 嵌入扩展 SME 匹配直接相关。

12. 总结与贡献

AlphaDetect 解决了 MIMO 检测中*可解释算法发现*这一困难问题。其主要贡献包括：

1. **概念创新的形式化刻画。**我们识别了三种形式（结构类比、优化驱动推导、算法组合），并将每种映射到一个可操作的自动化机制。
2. **带算法组合子及适配器的类型化 DSL。**DSL 提供了一种类型安全的组合式语言，可以表达已知算法并搜索新算法。
3. **问题变换库。**中间变量的发明被重新表述为类型化变换的见证生成，将开放式的创造行为转化为结构化搜索。
4. **自动算法推导的 CAS 集成。**我们展示 EP-MIMO 及其所有变体可以通过 CAS 驱动的坐标下降推导获得，腔分布和倾斜分布作为代数副产品自然出现。
5. **LLM 增强的结构映射引擎。**LLM 被用作谓词生成器和源域推荐器——提供语义桥接——而 SME 保证形式化的结构一致性，并生成驱动搜索的候选推断。
6. **统一的系统架构。**四个组件（DSL、变换、CAS、SME）被集成到一个内聚的系统中，配合 MCTS/进化搜索、复杂度评估、性能基准测试和自扩展概念空间。
7. **全面的案例研究。**通过 EP-MIMO、GTA 和 BP 引导的球形译码，我们展示了该框架覆盖了从纯代数推导到跨域结构类比再到类型引导算法组合的所有三种创新类型。

References

[1] D. Gentner, "Structure-mapping: A theoretical framework for analogy," *Cognitive Science*, vol. 7, no. 2, pp. 155–170, 1983.

[2] B. Falkenhainer, K. D. Forbus, and D. Gentner, "The structure-mapping engine: Algorithm and examples," *Artificial Intelligence*, vol. 41, no. 1, pp. 1–63, 1989.

[3] K. Ellis, C. Wong, M. Nye, M. Sable-Meyer, L. Cary, L. Morales, L. Hewitt, A. Solar-Lezama, and J. Tenenbaum, "DreamCoder: Bootstrapping inductive program synthesis with wake-sleep library learning," *Proc. ACM PLDI*, 2021.

[4] P. D. Turney, "The latent relation mapping engine: Algorithm and experiments," *Journal of Artificial Intelligence Research*, vol. 33, pp. 615–655, 2008.

[5] D. J. Chalmers, R. M. French, and D. R. Hofstadter, "High-level perception, representation, and analogy: A critique of artificial intelligence methodology," *Journal of Experimental & Theoretical Artificial Intelligence*, vol. 4, no. 3, pp. 185–211, 1992.

[6] T. P. Minka, "Expectation propagation for approximate Bayesian inference," *Proc. UAI*, pp. 362–369, 2001.

[7] C. Choi and A. Singer, "A tree-reweighted belief propagation algorithm for restoring sparse signals," *Proc. ICASSP*, 2006.

[8] S. Colton, *Automated Theory Formation in Pure Mathematics*. Springer, 2002.